PROJEKTARBEIT TEIL 1 · DATA ENGINEERING HS26

Beeinflusst das Wetter die Pünktlichkeit des öV?

Bahn und Bus in der Ostschweiz, Winter 2026

Gruppe 4: Timon, Aladin, Enis

Kolloquium 4. November 2026, 18:00 · Raum SW 111

Drei Pakete, je ca. 5 Minuten

Paket A · Timon

Konzept und Rahmen

Problemstellung, Forschungsfrage, Hypothesen, Methodik, Lifecycle

Paket B · Aladin

Daten rein

Ist-Daten, Ingestion, Storage-Entscheid, Datenmodell

Paket C · Enis

Daten verknüpfen

Wetterdaten, Bereinigung, Join, Resultate, Limitationen

Danach: Fragen und Diskussion im Plenum (7 Minuten)

Problemstellung: Wetter und Pünktlichkeit im öV

Verspätungen kosten Anschlüsse, Geld und Vertrauen. Im Winter kommen Niederschlag, Schnee und Frost dazu, die niemand steuern, aber berücksichtigen kann.

Pendlerinnen und Pendler

Wann ist mit Verspätungen zu rechnen?

ÖV-Betreiber

Ist Bus oder Bahn stärker betroffen?

Planerinnen und Planer

Wo lohnen sich Reserven im Fahrplan?

Untersuchungsgebiet: Thurgau, St. Gallen, Appenzell
Bahn und Bus · 1.1.–31.3.2026

Forschungsfrage und Hypothesen

Wie stark beeinflusst das Wetter die Pünktlichkeit des öffentlichen Verkehrs in der Ostschweiz, und unterscheidet sich der Effekt nach Verkehrsmittel und Tageszeit?

H1	Bei starkem Niederschlag oder Schnee ist die mittlere Verspätung höher als sonst.
H2	Der Effekt ist beim Bus stärker als bei der Bahn.
H3	Der Effekt ist in der Hauptverkehrszeit stärker als ausserhalb.

Operationalisierung und Methodik

Verspätung	Ankunft: Ist minus Soll in Minuten, nur gemessene Werte
Verspätet	ab 3 Minuten (Definition SBB AG, o. J.)
Starker Niederschlag	Stundensumme über dem 90. Perzentil der Regenstunden
Hauptverkehrszeit	Mo–Fr, 6–9 und 16–19 Uhr (Lokalzeit)
Plausibilität	–10 bis +60 Minuten, Ausfälle und Durchfahrten ausgeschlossen

Tests: H1 Mann-Whitney-U · H2 und H3 Regression mit Wechselwirkung
α = 0,05 · Effektstärke immer mit angegeben

Lifecycle und Unterströmungen

Generation

Ist-Daten v2
GTFS
swissBOUNDARIES3D
MeteoSchweiz

umgesetzt

Ingestion

Python-Skripte, Batch
ÖV: Monats-Zip
Wetter: STAC-CSV
idempotent

umgesetzt

Storage

DuckDB und Parquet
Daten auf OneDrive

umgesetzt

Transformation

Bereinigung
räumlicher und zeitlicher Join
Hypothesentests

umgesetzt

Serving

Web-Dashboard
Karte, Zeitreihen, Wetterfilter

Entwurf für Teil 2

Unterströmungen: Security · Data Management · DataOps · Data Architecture · Orchestration · Software Engineering

Stand: Generation bis Transformation sind umgesetzt, Serving ist der Entwurf für Teil 2.

Ist-Daten v2: jeder Halt mit Soll- und Ist-Zeit

Merkmal	Befund
Herkunft	Geschäftsstelle SKI (SBB AG) im Auftrag des BAV, opentransportdata.swiss
Zugang und Lizenz	Monatsarchiv als Zip, frei ohne Login, Quellenangabe Pflicht
Abdeckung	v2 ab Juli 2025, 1.1. bis 31.3.2026 vollständig (90 Tage)
Format	CSV mit Trennzeichen «;», UTF-8, 22 Spalten, eine Datei pro Tag
Grösse	420 bis 650 MB pro Tag, ca. 2,4 Mio. Zeilen (ganze Schweiz)
Zeitformat	Lokalzeit ohne Zeitzone, Sommerzeit am 29.3.2026 im Zeitraum

```
Wichtige Spalten: BETRIEBSTAG, PRODUKT_ID, LINIEN_TEXT, BPUIC, ANKUNFTSZEIT, AN_PROGNOSE,
AN_PROGNOSE_STATUS, FAELLT_AUS_TF, DURCHFAHRT_TF
```

Ingestion: ein Tag nach dem anderen, wiederholbar



Idempotent

Geladene Tage werden übersprungen, ein neuer Lauf erzeugt keine Duplikate.

Protokolliert

Pro Tag Zeilen vor und nach dem Filter, Dauer und Fehler in Logfile und Tabelle ingest_log.

Zeitzonen-sicher

Alle Zeiten als TIMESTAMPTZ (ISO 8601 mit Zeitzone), Sommerzeit korrekt.

```
python src/ingest_istdaten.py --start 2026-01-01 --end 2026-03-31 --stops
data/stammdaten/haltestellen_ostschweiz.csv
```

Von 215 Mio. auf 17 Mio. Zeilen

215 Mio.

Zeilen roh, 90 Tage, ganze Schweiz

2587

Haltestellen in SG, TG, AR und AI

17,07 Mio.

Halte in der Datenbank (Bahn 1,75, Bus 15,32)

Beim Laden bereinigt

- Exakte Duplikate entfernt, gemessener Wert vor Prognose
- 9-stellige BPUIC auf die 7-stellige Haltestelle gekürzt
- Lokalzeit in TIMESTAMPTZ (Europe/Zurich) umgewandelt

Offengelegt für Paket C

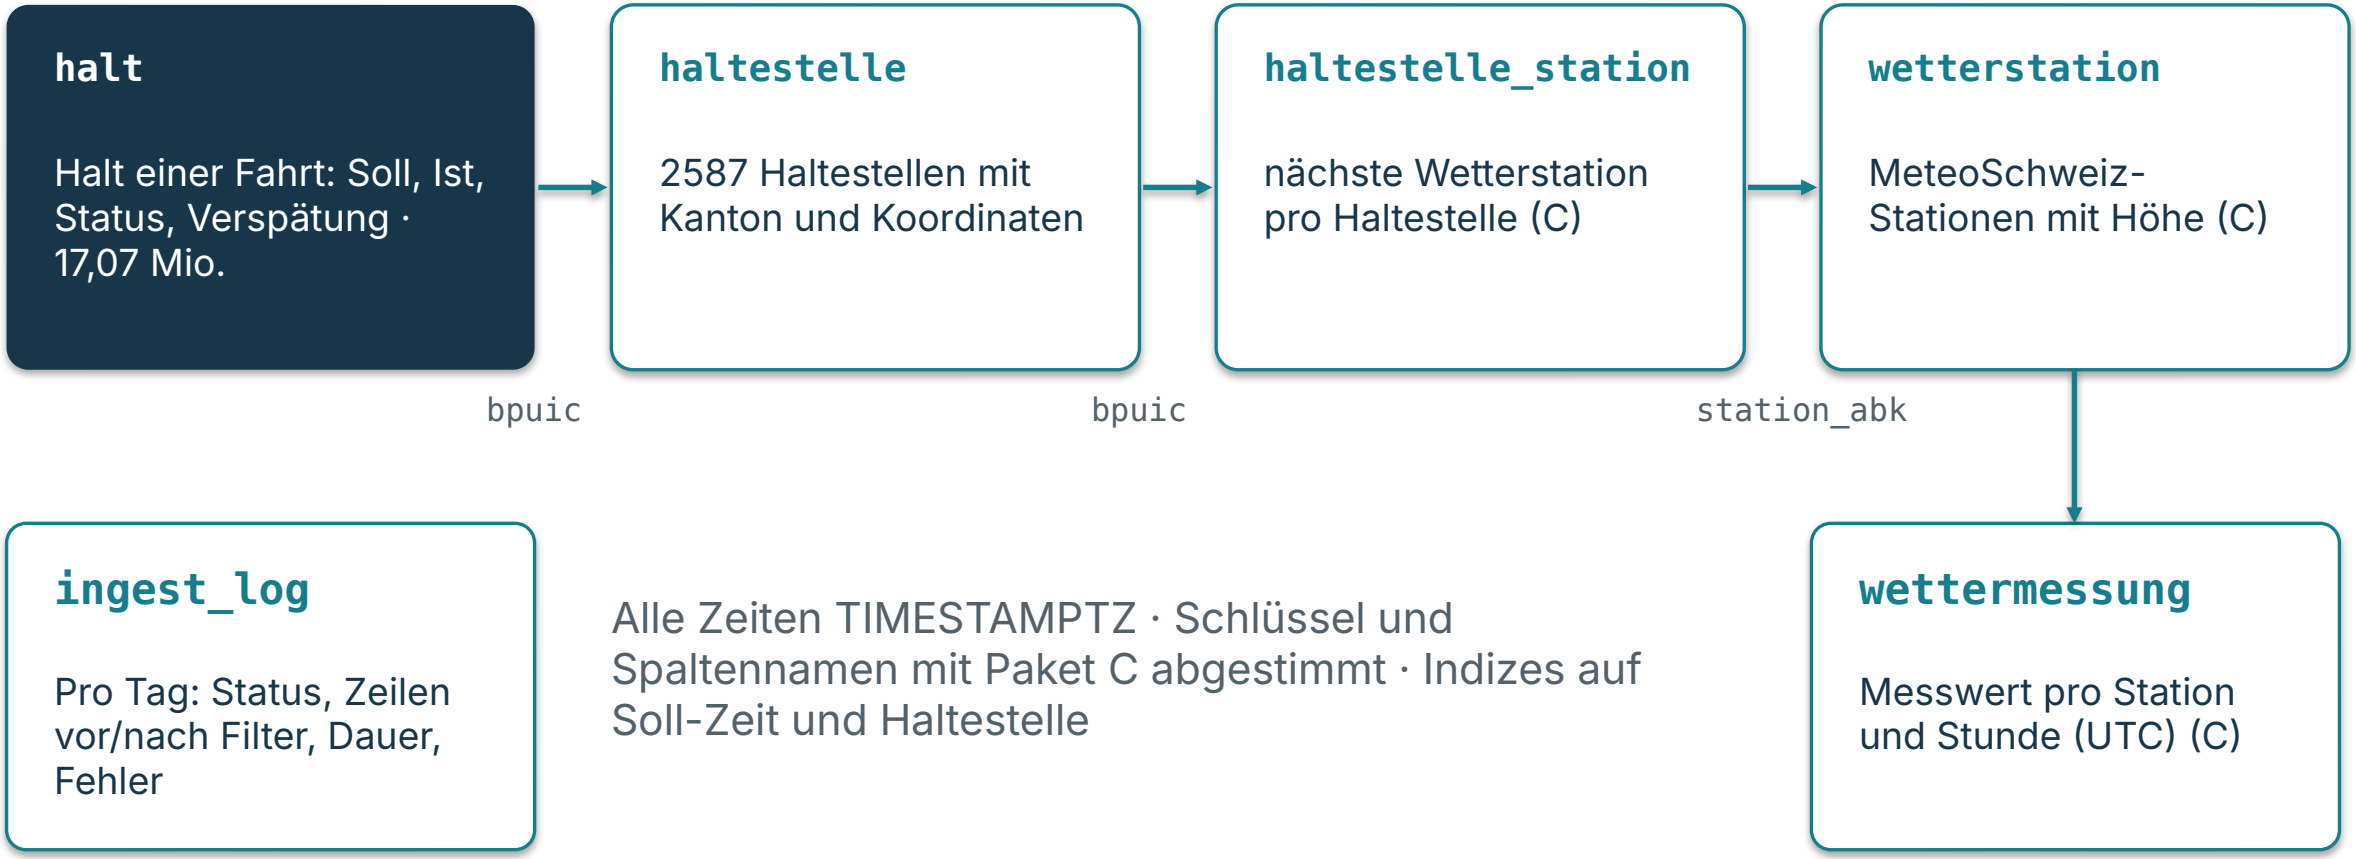
- Ankunft echt gemessen (REAL): Bahn 89,7 %, Bus 65,9 %
- Unplausible Ist-Zeiten (z. B. genau 1 Tag daneben) bleiben roh
- Status jeder Zeit (REAL, PROGNOSE, GESCHAETZT) wird mitgeführt

Storage: DuckDB – analytisch, eine Datei, kein Server

Kriterium	DuckDB	SQLite	PostgreSQL	MongoDB
Analytische Abfragen (Joins, GROUP BY)	sehr gut	mässig	gut	mässig
CSV streamend einlesen	sehr gut	mässig	gut	mässig
Zeitzonen (TIMESTAMPTZ)	gut	schwach	sehr gut	mässig
Skalierung auf mehr Kantone	gut	schwach	sehr gut	gut
Setup für die Gruppe	sehr gering	sehr gering	hoch (Server)	hoch (Server)
Viele gleichzeitige Nutzer	mässig	mässig	sehr gut	gut

Entscheid: DuckDB für Teil 1. Für das Dashboard in Teil 2 ist ein Wechsel auf PostgreSQL möglich, weil das Schema Standard-SQL ist.

Datenmodell: Halt und Wetter über die Haltestelle verknüpft



Alle Zeiten TIMESTAMPTZ · Schlüssel und Spaltennamen mit Paket C abgestimmt · Indizes auf Soll-Zeit und Haltestelle

Skalierbarkeit: gleicher Code, längere Haltestellenliste

Umfang	Zeilen	DuckDB	Parquet	Laufzeit
1 Tag, ganze Schweiz (gemessen)	2,34 Mio.	375 MB	ca. 45 MB	43 s
90 Tage, Ostschweiz (gemessen)	**17,07 Mio.**	**2,6 GB**	**305 MB**	**ca. 16 Min.**
90 Tage, ganze Schweiz (hochgerechnet)	ca. 210 Mio.	ca. 34 GB	ca. 4 GB	ca. 1 h

- Speicherbedarf beim Laden hängt nicht von der Dateigrösse ab, weil streamend gelesen wird.
- Mehr Kantone: nur die Haltestellenliste erweitern, Code und Schema bleiben gleich.
- Grenze: DuckDB erlaubt nur einen schreibenden Prozess; für Teil 2 ist PostgreSQL die nächste Stufe.

Wetterdaten passend zu jedem Halt

13 Stationen · 10 geeignet

MeteoSchweiz SwissMetNet, Januar–März 2026

Stundenwerte: Niederschlag und Temperatur; Wind und Schnee soweit verfügbar

QUI, SCM und STK fehlen die Kernparameter

2’540 Haltestellen zugeordnet

Nächste geeignete Station: höchstens 30 km und 500 m Höhenunterschied

Geländehöhen mit swisstopo ergänzt; 47 Haltestellen ohne passende Station

Join nach Soll-Ankunft und Wetterintervall in UTC

Bestehende Basis: Python + DuckDB + Parquet

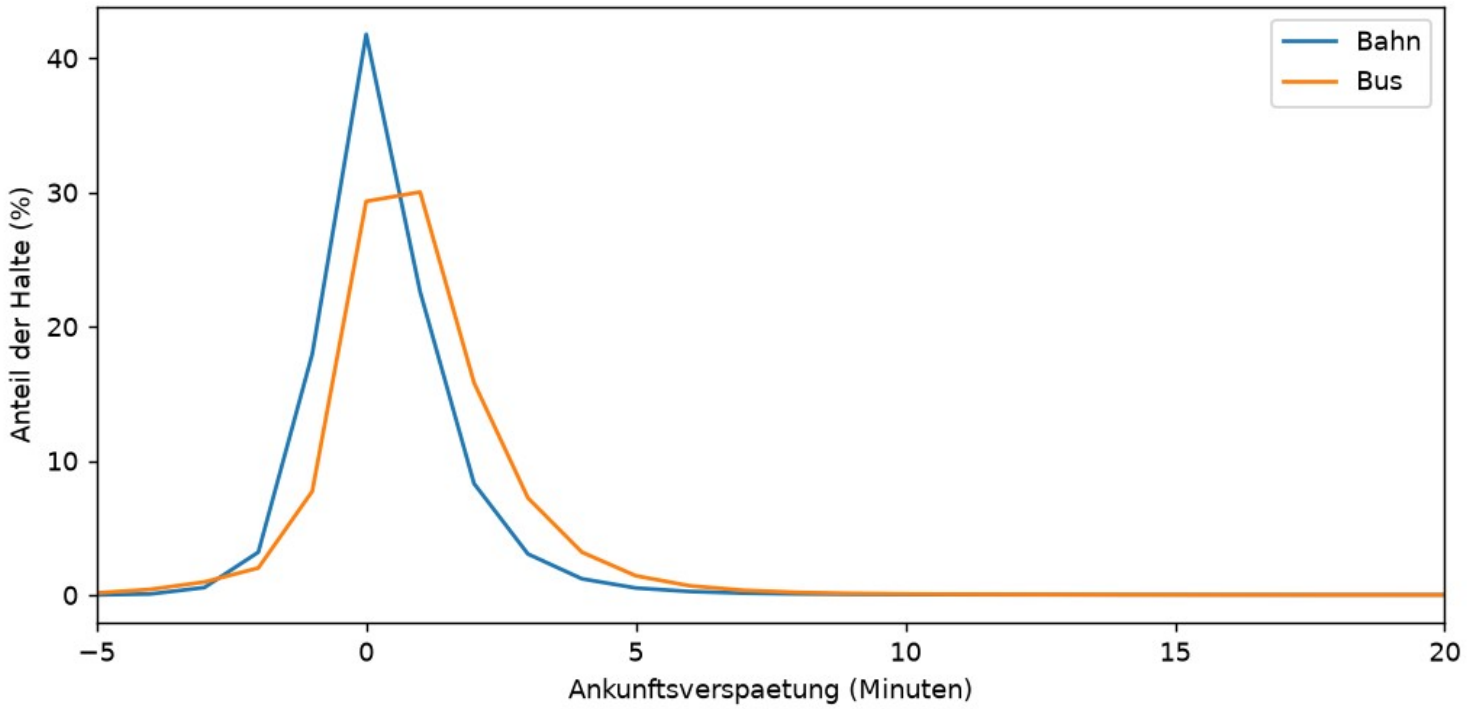
Bereinigung: von 17,07 auf 11,63 Mio. Halte

Nur gemessene Ankünfte (REAL)

Keine Ausfälle oder Durchfahrten

Plausibilität: −10 bis +60 Minuten

Verspätet: mindestens 3 Minuten

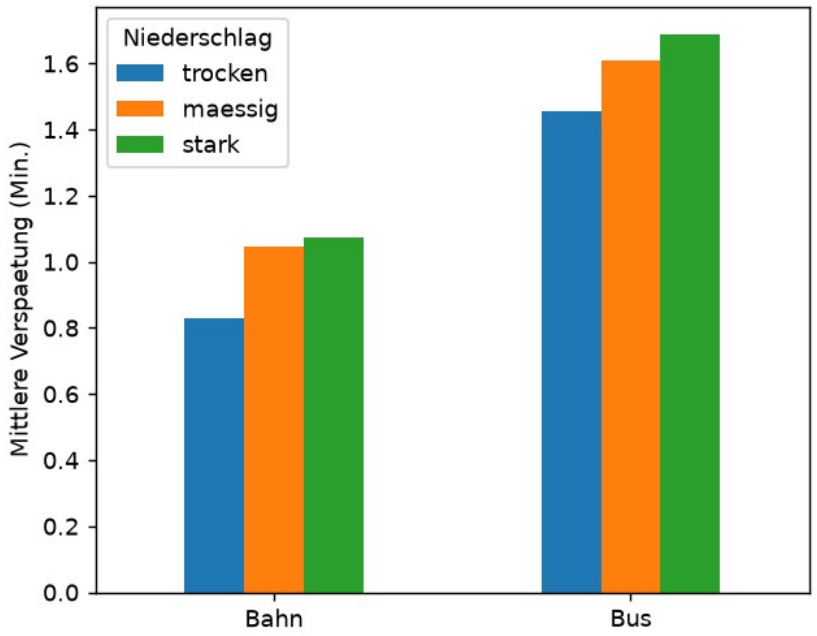


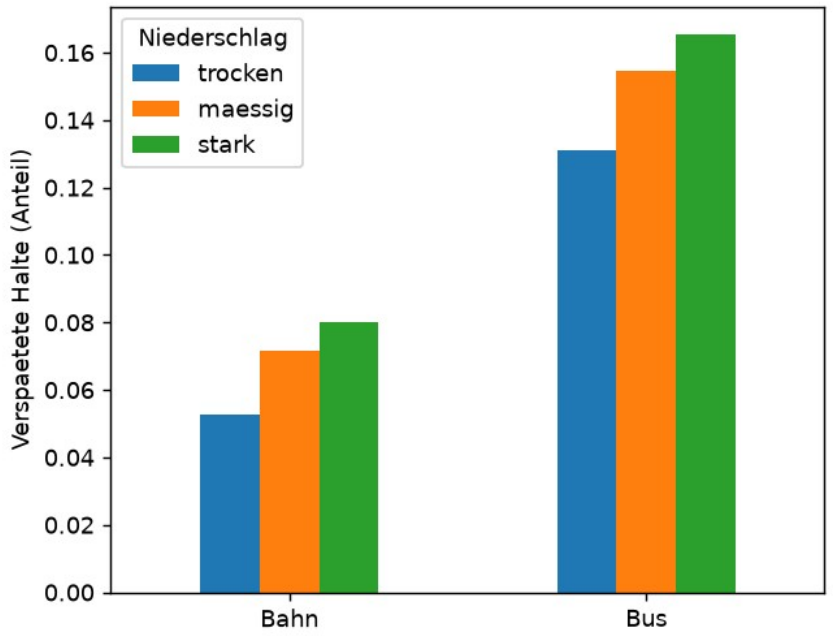
Ankunftsstatus REAL vor Bereinigung: Bahn 89,72 % · Bus 65,94 %

Unterschiedliche Messabdeckung bleibt eine Grenze des Vergleichs.

H1: Bei starkem Niederschlag etwas mehr Verspätung

+13,2 Sekunden im Mittel · 12,36 % → 15,50 % verspätete Halte





Stark: > 1.7 mm/h

Kleiner Effekt: r = 0,070

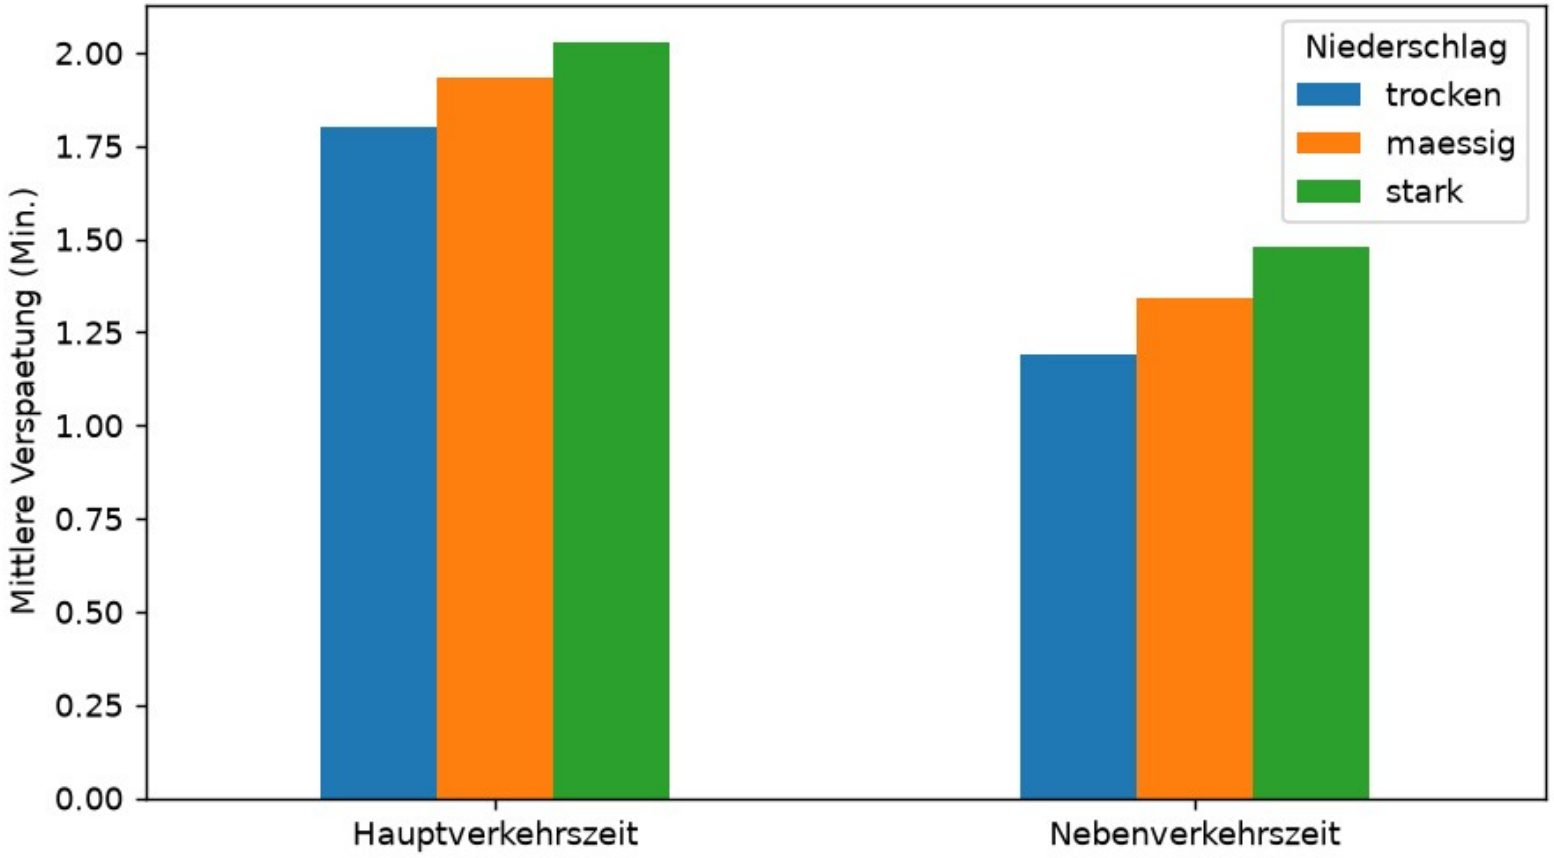
p < 0,001

H2 nicht gestützt:

Fast gleicher Wettereffekt bei Bus und Bahn

H1-Test: stark gegen sonst. Grafik: trocken / mässig / stark.

H3: Die Hauptverkehrszeit verstärkt den Effekt nicht



Wettereffekt stark vs. sonst:

HVZ: +0,208 Minuten

NVZ: +0,268 Minuten

Interaktion: -0.060 Minuten

H3 nicht gestützt

Höheres Verspätungsniveau in der HVZ ≠ stärkerer Wettereffekt.

Ein kleiner Zusammenhang – mit klaren Grenzen

Beobachteter Zusammenhang, keine Kausalität

Nur ein Winterquartal; weitere Ursachen fehlen

Halte derselben Fahrt sind nicht unabhängig

Wetterstation liegt nicht direkt am Halt

Unterschiedliche REAL-Abdeckung bei Bahn und Bus

Schneedecke und Frostniederschlag sind keine einheitliche Schneefallmessung

Für Teil 2 vorbereitet: bereinigte Halte + Stundenaggregation

Nachvollziehbar in ausgeführten Notebooks und DuckDB/Parquet.

Ausblick: Teil 2

Transformation

Feedback aus Teil 1 einarbeiten, finale Antwort auf die Forschungsfrage

Serving

Web-Dashboard mit Karte, Zeitreihen und Wetterfiltern

Skalierung

Mehr Kantone, Deutschschweiz oder ganze Schweiz, falls die Pipeline stabil läuft

Abgabe Teil 2: 8. Dezember 2026 · Fragen und Diskussion (7 Minuten)

Quellen (Anhang)

SBB AG, Geschäftsstelle Systemaufgaben Kundeninformation. (2026). Ist-Daten v2 [Datensatz]. Open-Data-Plattform Mobilität Schweiz.
https://archive.opentransportdata.swiss/actual_data_archive.htm

SBB AG, Geschäftsstelle Systemaufgaben Kundeninformation. (2026). Fahrplan 2026 (GTFS) [Datensatz]. Open-Data-Plattform Mobilität Schweiz.
https://archive.opentransportdata.swiss/timetable_gtfs.htm

Bundesamt für Landestopografie swisstopo. (2026). swissBOUNDARIES3D [Datensatz].
https://www.swisstopo.admin.ch

SBB AG. (o. J.). So misst die SBB die Pünktlichkeit [Webseite].
https://company.sbb.ch/de/unternehmen/verantwortung/kunden/puenktlichkeit.html

DuckDB Foundation. (2026). DuckDB documentation.
https://duckdb.org/docs/

Reis, J., & Housley, M. (2022). Fundamentals of data engineering. O'Reilly Media.

Weitere Quellen (MeteoSchweiz, swisstopo Höhendienst, SciPy, statsmodels): siehe Folie Quellen von Paket C und README.

Quellen (Anhang)

Bundesamt für Meteorologie und Klimatologie MeteoSchweiz. (2026). Automatische Wetterstationen: Messwerte [Datensatz]. Quelle: MeteoSchweiz.

https://data.geo.admin.ch/api/stac/v1/collections/ch.meteoschweiz.ogd-smn

SBB AG, Geschäftsstelle Systemaufgaben Kundeninformation. (2026). Ist-Daten v2 [Datensatz]. Open-Data-Plattform Mobilität Schweiz.

https://archive.opentransportdata.swiss/actual_data_archive.htm

Bundesamt für Landestopografie swisstopo. (2026). Height: GeoAdmin API [Höhendienst].

https://api3.geo.admin.ch/services/sdiservices.html#height

The SciPy community. (2026). scipy.stats.mannwhitneyu. Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.

https://www.statsmodels.org/stable/regression.html

Paket B: mögliche Fragen 1/2 (Anhang)

Warum nicht PostgreSQL?

Für Teil 1 brauchen wir Analyse, keinen Mehrbenutzerbetrieb. DuckDB ist schneller aufgesetzt und spaltenorientiert; das Schema ist Standard-SQL, ein Wechsel ist einfach.

Was heisst idempotent bei euch?

Jeder Tag wird in einer Transaktion gelöscht und neu eingefügt. Ein zweiter Lauf überspringt fertige Tage. Geprüft: zweiter Lauf, 90 Tage übersprungen.

Wie geht ihr mit der Sommerzeit um?

Rohzeiten sind Lokalzeit. Wir wandeln sie mit Europe/Zurich in TIMESTAMPTZ um, so stimmen Dauern über die Umstellung am 29.3.

Paket B: mögliche Fragen 2/2 (Anhang)

Wie zuverlässig sind die Ist-Zeiten?

Ankunft gemessen: Bahn 89,7 %, Bus 65,9 %, der Rest sind Prognosen oder Schätzungen. Der Status ist pro Zeit gespeichert, Paket C nimmt nur gemessene Werte.

Wie habt ihr die Haltestellen den Kantonen zugeordnet?

Koordinaten aus dem GTFS-Fahrplan, dann Punkt-in-Polygon mit den Kantonsgrenzen von swisstopo. Ergebnis: 2587 Haltestellen.

Warum liegen die Rohdaten nicht im Repo?

Rund 50 GB ungefiltert. Im Repo liegt ein Beispieltag, das Skript lädt alles mit einem Befehl nach. Die gefilterten Daten liegen als Parquet auf OneDrive.